Mémoire de projet

Fill-rouge – Analyse Prédictive Segmentation Clientèle

Hassan Issil

28 mars 2026

Résumé

Ce mémoire présente le projet final de la formation “ Analyse Prédictive Segmentation Clientèle”. L'objectif était de construire un modèle de prédiction de l'attrition client (‘churn‘) pour une banque fictive, en suivant l'ensemble des étapes d'un projet de data science : analyse exploratoire, préparation des données (ETL), modélisation par régression logistique, évaluation du modèle et interprétation des résultats. Le projet a été réalisé avec des outils professionnels : Tableau, SQL Server Integration Services (SSIS), SQL Server Management Studio (SSMS) et le logiciel économétrique gretl. Les résultats montrent que les principaux facteurs d'attrition sont le pays de résidence (Allemagne), le genre (femme) et l'inactivité du client. Des recommandations opérationnelles sont proposées pour aider la banque à réduire son taux de départ.

Table des matières

1 Introduction **3**
1.1 Contexte et problématique 3
1.2 Objectifs du projet 3
1.3 Structure du mémoire 3

2 Analyse exploratoire des données avec Tableau **3**
2.1 Présentation du jeu de données 3
2.2 Premiers tests visuels 3

3 Préparation des données (ETL) **4**
3.1 Phase 1 – Nettoyage initial des fichiers sources 4
3.2 Phase 2 – Chargement avec SSIS 4
3.3 Phase 3 – Nettoyage avancé avec SQL Server 4
3.3.1 Conversion de types et corrections 4
3.4 Contrôle de qualité 5

4 Modélisation **5**
4.1 Choix de l'algorithme 5
4.2 Construction du modèle avec gretl 5
4.3 Modèle final 6
4.4 Interprétation des coefficients (Odds Ratio) 6

5 Évaluation du modèle **6**
5.1 Courbe CAP (Cumulative Accuracy Profile) 6
5.2 Validation sur un test set 7

6 Recommandations et plan d'action **7**

7 Maintenance du modèle **7**

8 Conclusion **7**

A Annexe : Code SQL de la procédure stockée (extrait) **8**

B Annexe : Captures d'écran de la courbe CAP **8**

1 Introduction

1.1 Contexte et problématique

Dans le secteur bancaire, la fidélisation des clients est un enjeu majeur. Une banque a observé un taux d'attrition anormalement élevé. Elle dispose d'un échantillon de 10 000 clients pour lesquels elle a collecté diverses informations (crédit score, âge, solde, nombre de produits, etc.) ainsi que le statut (parti ou resté) après six mois d'observation. L'objectif est de comprendre les déterminants du départ et de construire un modèle prédictif pour identifier les clients à risque.

1.2 Objectifs du projet

- Réaliser une analyse exploratoire des données pour dégager des tendances initiales.
- Mettre en place un processus de préparation des données robuste (ETL) pour nettoyer et structurer les données.
- Construire un modèle de régression logistique pour prédire la probabilité de départ.
- Évaluer la performance du modèle et interpréter les résultats.
- Proposer des recommandations concrètes pour améliorer la fidélisation.

1.3 Structure du mémoire

Le mémoire suit le déroulement chronologique du projet : compréhension du besoin, analyse exploratoire, préparation des données, modélisation, évaluation, et enfin stratégie de maintenance du modèle.

2 Analyse exploratoire des données avec Tableau

2.1 Présentation du jeu de données

Le jeu de données `Churn Modeling` contient 10 000 lignes et plusieurs variables (identifiant client, crédit score, pays, genre, âge, ancienneté (tenure), solde (balance), nombre de produits, carte de crédit, client actif, salaire estimé, et la variable cible `Exited` (1 si le client est parti, 0 sinon).

2.2 Premiers tests visuels

À l'aide de Tableau, nous avons construit des graphiques simples pour visualiser les taux de départ par catégorie. Les résultats suivants ont été observés :

- **Genre** : 25% des femmes ont quitté la banque contre 16% des hommes.
- **Pays** : 32% des clients allemands sont partis, contre 16% en France et 17% en Espagne.
- **Activité** : 27% des clients inactifs ont quitté la banque contre seulement 14% des actifs.

— **Nombre de produits** : anomalie sur les clients ayant 3 ou 4 produits (taux de départ très élevé), mais avec un faible effectif.

Ces premières observations ont orienté la suite du travail : les variables `Geography`, `Gender` et `IsActiveMember` semblent avoir un fort pouvoir discriminant.

3 Préparation des données (ETL)

3.1 Phase 1 – Nettoyage initial des fichiers sources

Les données brutes (`Fake Names` et `Churn Modeling`) présentaient plusieurs problèmes typiques du monde réel :

— Formats de date incohérents (mois/jour/année au lieu de année-mois-jour).

— Virgules dans les commentaires brisant la structure CSV.

— Numéros de carte de crédit convertis en notation scientifique par Excel.

La solution a consisté à :

1. Utiliser `Notepad++` pour inspecter les fichiers et identifier les anomalies.
2. Ouvrir les fichiers dans Excel via l'assistant d'importation de texte, en forçant le type `Texte` pour toutes les colonnes.
3. Appliquer les corrections nécessaires (formats date, suppression des symboles monétaires, conversion des pourcentages).
4. Sauvegarder en CSV.

3.2 Phase 2 – Chargement avec SSIS

Le chargement a été automatisé avec SQL Server Integration Services (SSIS). Un package a été créé comportant :

— Une source `Flat File Source` pointant vers le fichier CSV préparé.

— Une destination `OLE DB Destination` vers une table `RAW` dans la base de données.

— Un composant `Conditional Split` pour séparer les lignes valides des lignes corrompues ou avec données manquantes.

Les lignes rejetées ont été redirigées vers des fichiers texte pour analyse ultérieure, assurant ainsi une traçabilité complète.

3.3 Phase 3 – Nettoyage avancé avec SQL Server

Après le chargement, une procédure stockée a été écrite pour transformer la table `RAW` (toutes colonnes en `VARCHAR`) en une `WORK` table avec des types adaptés.

3.3.1 Conversion de types et corrections

Listing 1 – Exemple de conversion de type

```
-- Cr ation de la table de travail
CREATE TABLE [dbo].[WRK_ChurnModeling] (
```

```sql
    RowNumber INT IDENTITY(1,1),
    CreditScore INT,
    Geography_Germany BIT,
    Gender_Female BIT,
    Age INT,
    Tenure INT,
    Balance FLOAT,
    NumOfProducts INT,
    IsActiveMember BIT,
    EstimatedSalary FLOAT,
    LogBalance FLOAT
);
```

Des corrections spécifiques ont été apportées :

- **Préfixes zéro** : la fonction `RIGHT('0000000' + CustomerId, 7)` a été utilisée pour uniformiser les identifiants clients.
- **Balance** : la fonction `ISNUMERIC` a permis d'exclure les lignes où la balance n'était pas un nombre (ex. texte "Visa").
- **Zip code** : la fonction `LEN` a permis de détecter les codes postaux dépassant 7 caractères (au Canada, format A1A 1A1).
- **Date de naissance** : la fonction `ISDATE` a filtré les dates invalides.
- **Exclusions additionnelles** : après insertion, des requêtes `DELETE` ont supprimé les valeurs aberrantes (balance négative, âge > 100 ans, etc.).

3.4 Contrôle de qualité

À chaque étape, des comptages ont été effectués pour vérifier que le nombre total d'enregistrements restait cohérent. La somme des revenus estimés (colonne `EstimatedSalary`) a été comparée à une valeur de référence fournie par le métier (419 896 187,87 $) pour valider l'intégrité des données.

4 Modélisation

4.1 Choix de l'algorithme

La variable cible `Exited` étant binaire (0/1), la régression logistique a été retenue. Elle permet d'estimer la probabilité de départ d'un client.

4.2 Construction du modèle avec gretl

Le logiciel gretl a été utilisé pour sa simplicité et sa focalisation sur l'interprétation statistique. La méthode **Backward Elimination** a été appliquée pour sélectionner les variables pertinentes. Le seuil de significativité initial était de 5%, mais le **R-squared ajusté** a servi de critère final pour éviter le sur-ajustement.

4.3 Modèle final

Après itérations, le modèle final a retenu les variables suivantes (toutes significatives avec p-value $< 5\%$) :

- `CreditScore`
- `Geography_Germany` (demi-variable)
- `Gender_Female` (demi-variable)
- `Age`
- `Tenure`
- `NumOfProducts`
- `IsActiveMember`
- `LogBalance` (logarithme du solde)

4.4 Interprétation des coefficients (Odds Ratio)

Pour quantifier l'impact de chaque variable, les odds ratios (OR = $e^{\text{coefficient}}$) ont été calculés.

Table 1 – Odds Ratios des variables du modèle final

Variable	**Coefficient**	**Odds Ratio**
Geography_Germany	0.741	2.10
Gender_Female	0.525	1.69
IsActiveMember	-1.076	0.34
Age	0.073	1.075
CreditScore	-0.001	0.999
Tenure	-0.023	0.977
NumOfProducts	-0.100	0.905
LogBalance	0.092	1.096

Interprétation :

- Un client allemand a 2,1 fois plus de risques de partir qu'un client français.
- Une femme a 1,69 fois plus de risques qu'un homme.
- Un client actif a 66% de risques en moins de partir.
- Une augmentation de l'âge d'un an multiplie le risque par 1,075.

5 Évaluation du modèle

5.1 Courbe CAP (Cumulative Accuracy Profile)

La courbe CAP a été construite à partir des probabilités prédites. Elle compare la performance du modèle à un modèle aléatoire et à un modèle idéal.

Résultat : Le score X (projection de l'abscisse 50% sur la courbe) est d'environ 80%, ce qui place le modèle dans la catégorie « très bon ». Cela signifie qu'en contactant 50% des clients les plus à risque selon le modèle, on identifie 80% des clients qui vont effectivement partir.

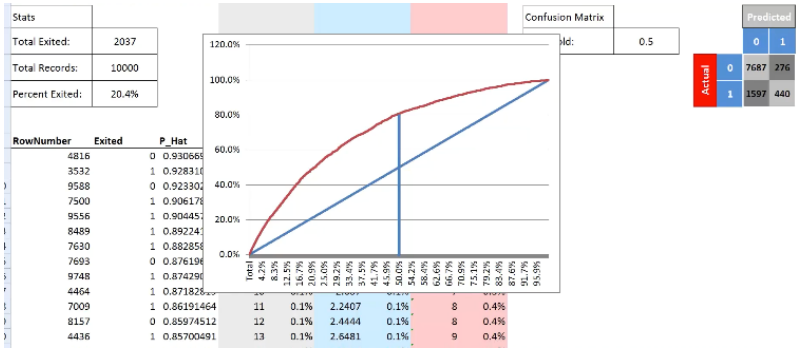

FIGURE 1 – Courbe CAP du modèle final

5.2 Validation sur un test set

Un second jeu de données (test set) de 1 000 clients a été utilisé pour valider la généralisation du modèle. Le score X sur ce test set était de 78%, confirmant la robustesse du modèle.

6 Recommandations et plan d'action

Sur la base des insights du modèle, trois actions prioritaires sont proposées :

1. **Marché allemand** : Mener une étude concurrentielle approfondie et revoir l'offre produit pour mieux répondre aux attentes des clients en Allemagne.
2. **Activation des clients** : Lancer des campagnes de communication et des offres promotionnelles ciblant les clients inactifs pour les encourager à utiliser leurs comptes.
3. **Segmentation par genre** : Analyser les besoins spécifiques des clientes et adapter les services (ex. conseils financiers dédiés, produits d'épargne) pour réduire leur taux de départ.

7 Maintenance du modèle

Pour assurer la pérennité du modèle, une procédure de maintenance en trois étapes (**RRR**) a été définie :

1. **Évaluer** : Tous les six mois, la courbe CAP est recalculée sur des données récentes.
2. **Re-entraîner** : Si la performance baisse, le modèle est ré-entraîné sur les nouvelles données (mêmes variables).
3. **Reconstruire** : Si la baisse est trop importante, une refonte complète du modèle est entreprise (sélection des variables, nouvelles transformations).

8 Conclusion

Ce projet de fin de formation a permis de mettre en avant l'intégralité d'un cycle de data science. Partant de données brutes et corrompues, un pipeline ETL robuste

a été construit, un modèle prédictif performant a été développé et interprété, et des recommandations opérationnelles ont été formulées. Les compétences mobilisées (Tableau, SSIS, SQL, gretl) démontrent la capacité à transformer des données en valeur ajoutée business.

A Annexe : Code SQL de la procédure stockée (extrait)

B Annexe : Captures d'écran de la courbe CAP

Les figures suivantes illustrent la courbe CAP obtenue sur le training set et sur le test set.

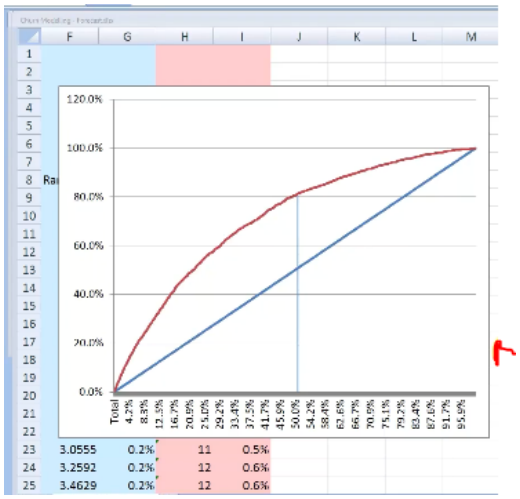

(a) Courbe CAP – Training set

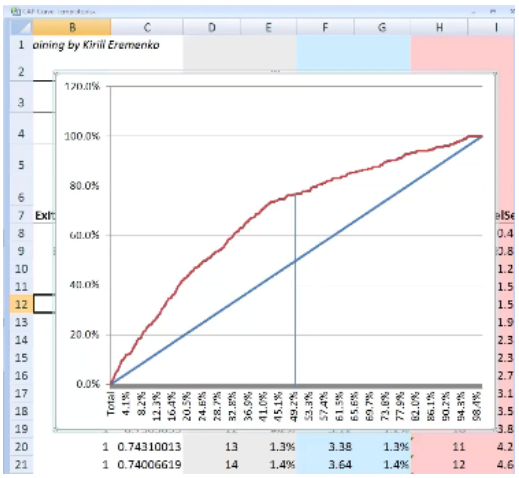

(b) Courbe CAP – Test set

FIGURE 2 – Comparaison des courbes CAP