Prédiction du Taux d'Attrition Client (Churn) pour une Banque

Optimisation de la fidélisation grâce à la Segmentation Géo-démographique

Par : Hassan ISSIL

Introduction & Problématique

Contexte & Objectif du Projet

- **La banque observe un taux de départ anormal de ses clients.**
- **Objectif : Identifier les segments de clients les plus susceptibles de quitter la banque pour agir de manière préventive.**
- **Résultat souhaité : Proposer des offres ciblées pour améliorer la fidélisation.**

Aperçu du Dataset

Variables clés :

- **Comportement financier : CreditScore, Balance (solde), EstimatedSalary.**
- **Relation client : Tenure (ancienneté), NumOfProducts, IsActiveMember.**
- **Démographie : Age, Gender (genre), Geography (pays : France, Allemagne, Espagne).**
- **Variable cible (à prédire) : Exited (1 = client parti, 0 = client resté)**

RowNumb	Customer	Surname	CreditSco	Geograph	Gender	Age	Tenure	Balance	NumOfPr	HasCrCard	IsActiveM	Estimated	Exited
1	15634602	Hargrave	619	France	Female	42	2	0	1	1	1	101348.88	1
2	15647311	Hill	608	Spain	Female	41	1	83807.86	1	0	1	112542.58	0
3	15619304	Onio	502	France	Female	42	8	159660.8	3	1	0	113931.57	1
4	15701354	Boni	699	France	Female	39	1	0	2	0	0	93826.63	0
5	15737888	Mitchell	850	Spain	Female	43	2	125510.82	1	1	1	79084.1	0
6	15574012	Chu	645	Spain	Male	44	8	113755.78	2	1	0	149756.71	1
7	15592531	Bartlett	822	France	Male	50	7	0	2	1	1	10062.8	0
8	15656148	Obinna	376	Germany	Female	29	4	115046.74	4	1	0	119346.88	1
9	15792365	He	501	France	Male	44	4	142051.07	2	0	1	74940.5	0

Nettoyage & Préparation des données brutes

- Récupération du fichier CSV source (données brutes).
- Problèmes courants : virgules dans les commentaires, dates au mauvais format, perte des zéros non significatifs.
- Solutions :
  - Utilisation de Notepad++ pour inspection manuelle.
  - Correction via Assistant d'importation texte Excel (délimiteur, guillemets, types texte forcé).
  - Suppression manuelle des lignes corrompues (ex: ligne 81).
- Diagramme (Format Mermaid) :

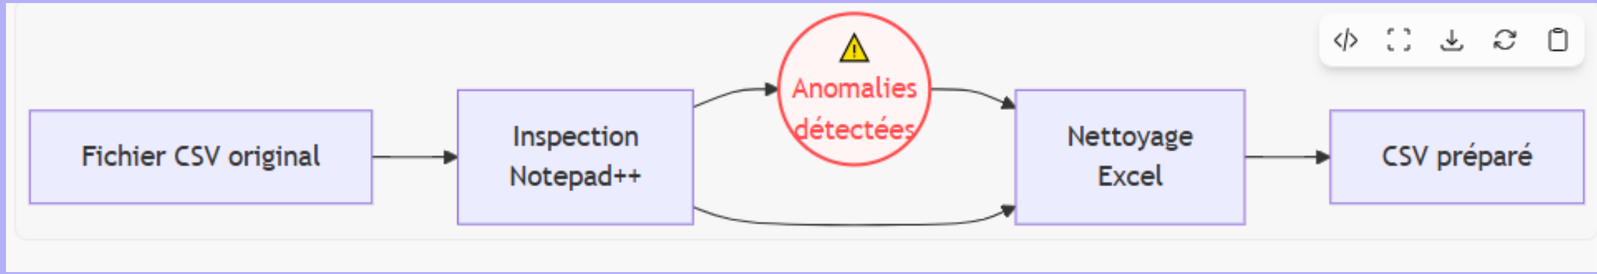

Intégration avec SQL Server Integration Services (SSIS)

Création d'un projet SSIS.

- **Composants utilisés :**
  - **Flat File Source (fichier CSV préparé)**
  - **Conditional Split (filtrage des anomalies)**
  - **OLE DB Destination (table RAW dans SQL Server)**
- **Règles de filtrage :**
  - **Colonne Feedback trop longue → redirigée vers fichier d'erreurs.**
  - **Colonnes vides ou décalées → fichiers Bad Records / Insufficient Data.**
- **Résultat : une table RAW propre avec toutes les colonnes en type texte.**

Diagramme (Format Mermaid) :

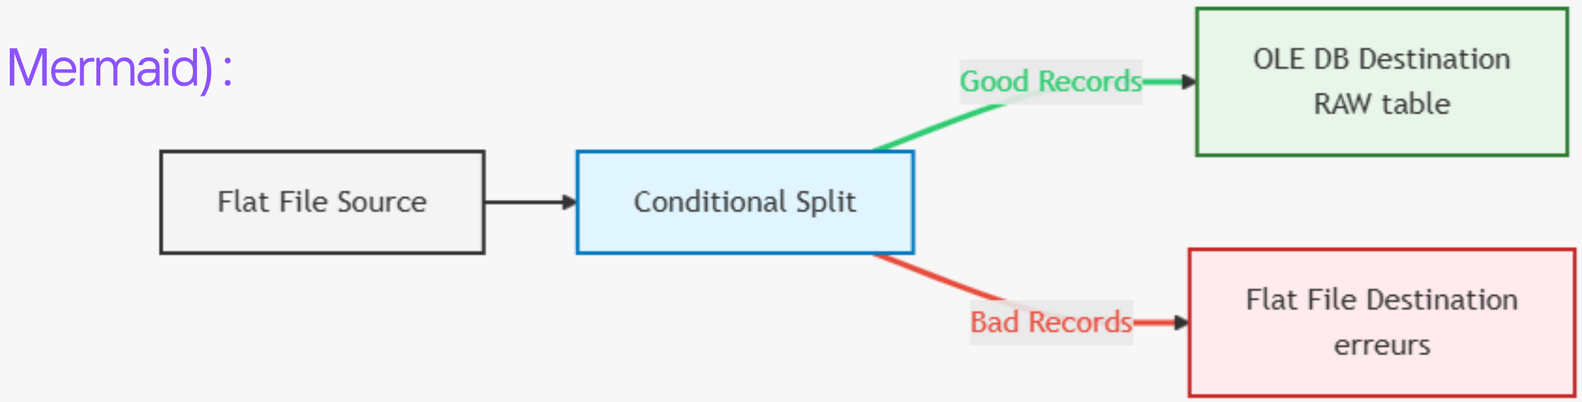

Transformation & Nettoyage avancé (Stored Procedures)

Passage de la table RAW (tout texte) à la table WORK (types corrects).

Utilisation d'une procédure stockée (template bld_wrk_...).

Étapes :

- DROP TABLE IF EXISTS (recréation propre)
- CREATE TABLE avec types adéquats (INT, FLOAT, DATE, VARCHAR(n))
- TRUNCATE (vide la table)
- INSERT INTO ... SELECT ... avec conversions implicites/explicites

Filtres supplémentaires pendant l'insertion :

- ISNUMERIC(balance)=1
- LEN(zipcode) <= 7
- ISDATE(birthday)=1

Contrôle qualité final : somme des revenus prédits = 419,896,187.87$

Diagramme (Format Mermaid)

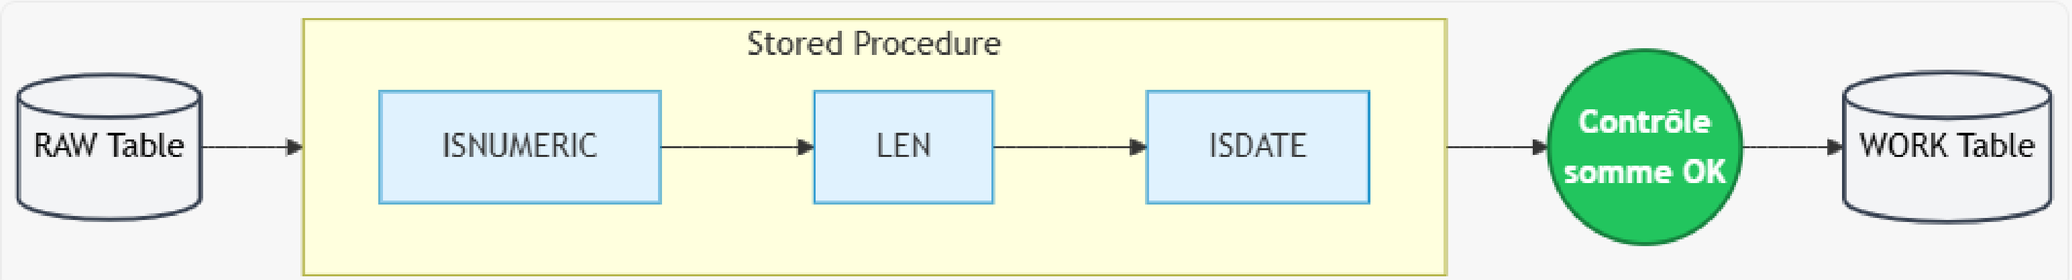

Analyse exploratoire & Insights visuels

Premiers Insights Visuels (via Tableau)

Graphique 1 : Taux de départ par genre → Les femmes sont plus susceptibles de partir que les hommes (25% vs 16%).

Graphique 2 : Taux de départ par pays → L'Allemagne a un taux de départ (32%) bien supérieur à la France (16%) et l'Espagne (17%).

Graphique 3 : Taux de départ par statut d'activité → Les clients inactifs partent deux fois plus (27% vs 14%).

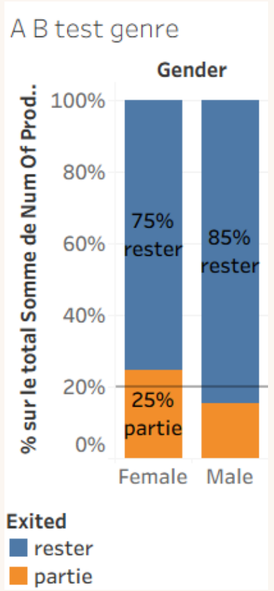

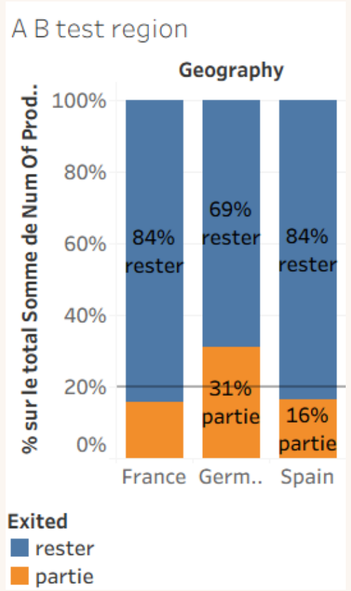

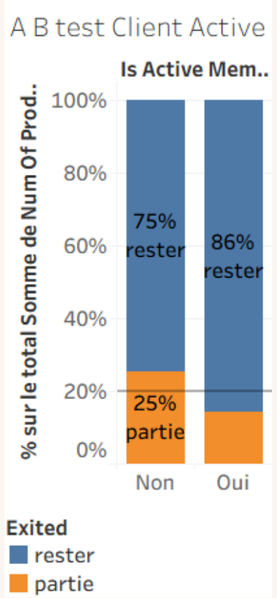

Modélisation – Régression Logistique

Pourquoi la régression logistique ?

- Variable cible binaire (parti / resté).
- Permet de calculer une probabilité de départ pour chaque client.
- Processus de construction du modèle :

1. Préparation des données (création de variables dummy, transformation log).
2. Sélection des variables (méthode "Backward Elimination").
3. Évaluation du modèle (Courbe CAP).

Diagramme (Format Mermaid) :

inputs ----------> Boîte noire ----------> Output .
(variables) (Régression Logistique) (Probabilité)

Facteurs Clés du Départ des Clients

Présenter un tableau ou des puces avec les principaux facteurs.

Le facteur le plus influent :

Germany : Un client en Allemagne a 2.1 fois plus de chances de partir qu'un client en France (toutes choses égales par ailleurs).

Autres facteurs significatifs :

Female : Une cliente a 1.7 fois plus de chances de partir qu'un client homme.

IsActiveMember : Un client inactif a presque 3 fois plus de chances de partir.

		Num Of Products			
Gender	Geography	1	2	3	4
Female	France	44 289	40 012	2 460	907
	Germany	27 004	17 982	2 315	603
	Spain	20 617	20 116	1 721	234
Male	France	54 198	48 641	2 139	452
	Germany	27 728	21 816	1 876	463
	Spain	27 862	24 722	979	82

Évaluation – Courbe CAP

La courbe CAP mesure l'efficacité du modèle à cibler les clients à risque.
Interprétation : En contactant seulement 50% des clients (ceux avec la plus forte probabilité prédite), le modèle permet de trouver ~80% de tous les clients qui allaient partir.

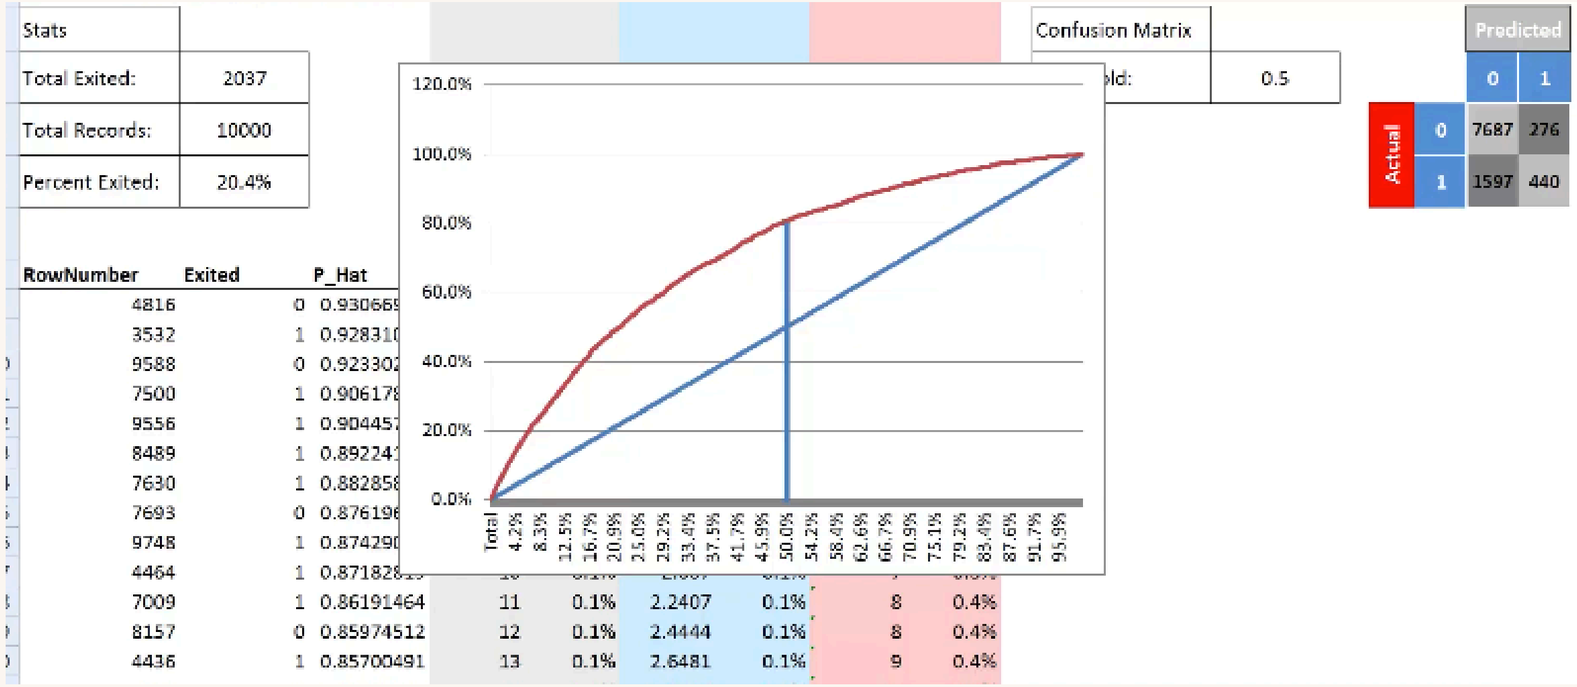

Conclusion : Le modèle est très performant et nettement meilleur qu'une sélection aléatoire (droite bleue).

Recommandations business

Transformer les insights en actions concrètes :

- Priorité 1 (Allemagne) : Lancer une enquête concurrentielle et revoir l'offre commerciale en Allemagne. Un problème structurel ou un concurrent agressif y est présent.

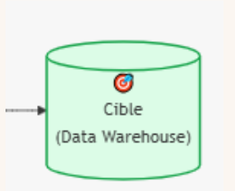

- Priorité 2 (Genre) : Développer des offres spécifiques pour les femmes (programme de fidélité, avantages sur des produits ciblés).

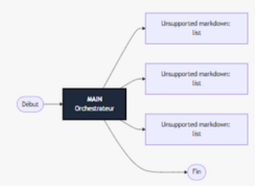

- Priorité 3 (Activité) : Lancer une campagne d'engagement pour les clients inactifs (notifications, conseils personnalisés, avantages à l'usage).

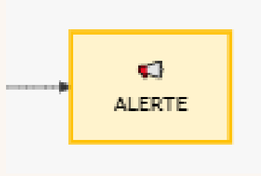

Maintenance & prochaines étapes

Assurer la Performance dans la Durée

Le modèle se détériore avec le temps (évolution des comportements, des marchés).

Processus RR :

R1 - Re-train : Ré-entraîner le modèle tous les 6 mois sur les nouvelles données.

R2 - Rebuild : Reconstruire entièrement le modèle si les performances chutent trop (score CAP < 60%).

Prochaine phase : Mettre en place un tableau de bord de suivi du taux de churn.

Conclusion & Valeur Ajoutée

- Le modèle de régression logistique identifie avec précision les clients à risque.
- Il permet un ciblage marketing efficace (80% des partants trouvés en ne contactant que 50% des clients).
- Bénéfice attendu : Réduction du taux d'attrition, optimisation du budget marketing et augmentation de la fidélité client.

MERCI

14.00
12.00
10.00
8.00
6.00
Series 1 (left axis)
Series 2 (right axis)
Jul
PART 7